

ТЗ

Техническое задание: Разработка Python-парсера ГРКИ (Росреестр)

1. Общее описание задачи

Необходимо разработать консольный скрипт на Python для сбора глубоких исторических данных из личных карточек кадастровых инженеров с официального сайта Росреестра. В качестве входных данных предоставляется CSV-файл (~40 000 строк) со списком кадастровых инженеров. В нем уже заполнены первые 6 колонок (Фамилия, Имя, Отчество, Регистрационный номер, Статус, Дата регистрации).

Парсер должен последовательно брать **«Регистрационный номер»** из файла, открывать по нему карточку на сайте и собирать данные из вложенных таблиц.

2. Требования к архитектуре и качеству кода

- **Стек:** Python 3.10+, Playwright или Selenium (для эмуляции действий в браузере и кликов по вкладкам) + BeautifulSoup4 для быстрого разбора HTML.
- **Структура кода:** Код должен быть модульным. Функции сбора данных (экстракт) должны быть жестко отделены от функций записи в файлы. Код должен быть снабжен подробными комментариями на русском языке для возможности его последующей интеграции бэкенд-разработчиком в базу данных PostgreSQL.
- **Конфигурация:** Все изменяемые настройки (пути к файлам, таймауты, задержки, прокси) должны быть вынесены в отдельный файл настроек `config.py`.

3. Требования к отказоустойчивости и логированию

- **Чекпоинты:** Скрипт должен сохранять промежуточный прогресс в режиме реального времени (запись в файлы после каждого успешно обработанного ID). При падении сайта или обрыве связи скрипт должен перезапускаться с места остановки, а не начинать заново.
- **Логирование ошибок:** При возникновении ошибки на конкретной карточке (Timeout, ошибка прокси, Parsing Error) скрипт не должен падать. Он обязан зафиксировать сбой в файл лога `errors.log` в формате: [Дата/Время] – [Регистрационный номер] – [Тип ошибки (например: HTTP 504 / Таблица статистики не найдена)], пропустить эту карточку и перейти к следующей.
- **Обход защит:** Поддержка работы через пул ротлируемых HTTP/SOCKS прокси-серверов.

4. Требования к комплектности сдачи проекта

Исполнитель передает ZIP-архив, содержащий:

1. Исходный код парсера (.py файлы) с комментариями.
2. Файл зависимостей (`requirements.txt`).
3. Инструкцию по запуску и настройке (`README.md`).
4. Итоговые заполненные CSV-файлы по всей базе.

5. Структура выходных данных

На выходе скрипт должен сформировать (дописать) ЧЕТЫРЕ связанных CSV-файла (кодировка UTF-8, разделитель — точка с запятой ;). Связующий ключ — уникальный регистрационный_номер из исходного файла.

Таблица 1. Основная база инженеров (engineers.csv)

Парсер берет исходный файл и дописывает в него 4 новые колонки из блока «Общие сведения» карточки:

1. **фамилия** (уже заполнено)
2. **имя** (уже заполнено)
3. **отчество** (уже заполнено)
4. **регистрационный_номер** (уже заполнено — уникальный ID)
5. **статус** (уже заполнено)
6. **дата_регистрации** (уже заполнено)
7. **номер_аттестата** (из карточки)
8. **дата_аттестата** (из карточки)
9. **реестровый_номер_СРО** (из карточки)
10. **текущая_дата_членства_в_СРО** (из карточки)

Таблица 2. История членства в СРО (sro_history.csv)

Сюда копируются все строки из таблицы «Членство в саморегулируемых организациях»:

1. **регистрационный_номер** (для связи с первой таблицей)
2. **наименование_СРО**
3. **дата_включения**
4. **дата_исключения** (если пусто на сайте — оставлять пустым)
5. **основание_исключения** (если пусто на сайте — оставлять пустым)

Таблица 3. Дисциплинарные воздействия (disciplinary_actions.csv)

Сюда копируются все строки из таблицы «Дисциплинарные воздействия». Если таблица пустая, инженера в этом файле не будет:

1. **регистрационный_номер** (для связи с первой таблицей)
2. **мера_ДВ**
3. **дата_решения**
4. **основание_применения**
5. **дата_началу_ДВ**
6. **дата_окончания_ДВ**

Таблица 4. Результаты деятельности (professional_activity.csv)

Сюда копируются все строки из таблицы «Результаты профессиональной деятельности» нарастающим итогом «как есть». Если в ячейке прочерк или пусто — записывать цифру 0:

- 1. регистрационный_номер** (для связи с первой таблицей)
- 2. год**
- 3. период** (3, 6, 9 или 12)
- 4. решений_об_осуществлении_и_отказе**
- 5. отказов_по_статье_27**
- 6. решений_об_устранении_ошибок**
- 7. решений_о_приостановлении**

6. Промежуточный контроль и приемка работы

Перед финальной выгрузкой всего массива данных (40 000 записей) прошу предоставить тестовый срез (первые 50 строк) в виде четырех получившихся CSV-таблиц. Это необходимо для подтверждения корректности сбора, кодировки и связей между таблицами, после чего запускается финальный парсинг всей базы.